

Графовые модели для построения карты связности функциональных групп

Панченко С.К., Вареник Н.В., Стрижов В.В.

Московский физико-технический институт
Москва, ФИЦ Информатика и управление РАН

Москва,
2022 г.

Общая схема Brain Computer Interface (BCI)

Multi-modal signals of brain-computer interfaces

Stimulus

Video $30\text{Hz} \times 1280 \times 1024$

Sound $48\text{kHz} \times 2$

Environment $\sim 10\text{Hz}$

Control

ECoG $1000\text{Hz} \times 64$

EEG $1000\text{Hz} \times 64$

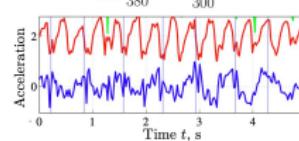
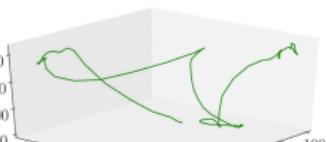
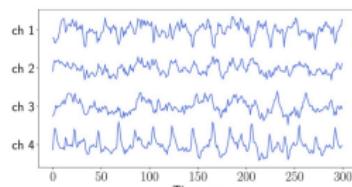
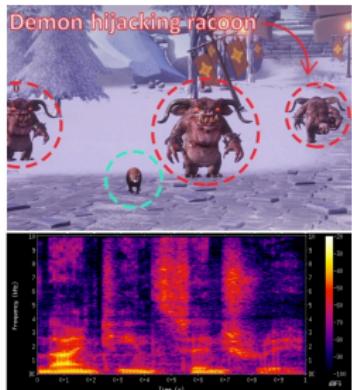
fMRI $5\text{Hz} \times 1024^3$

Action

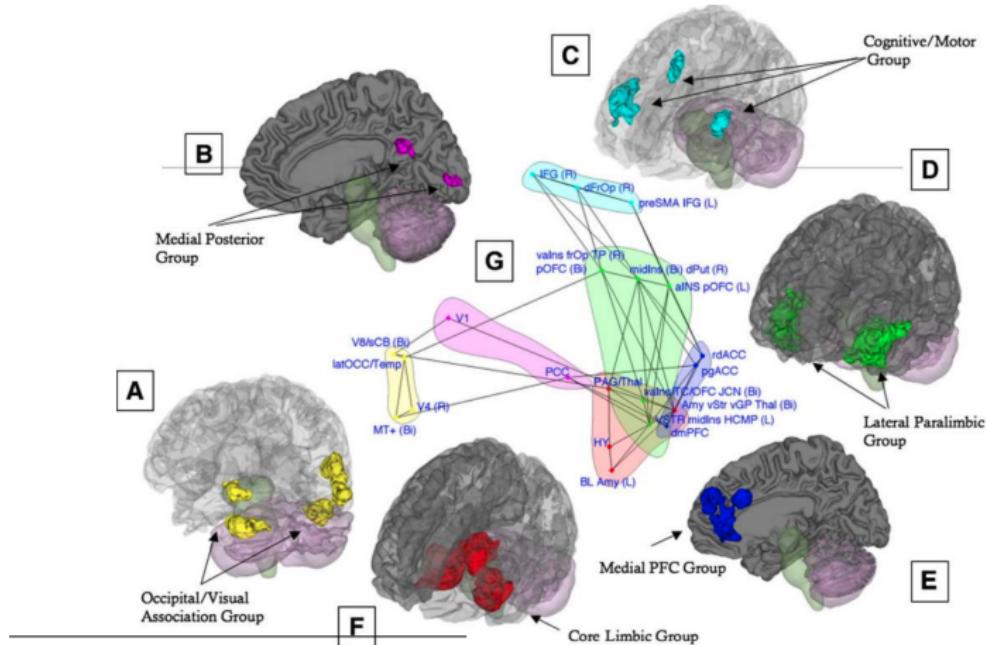
Eye track $30\text{Hz} \times 3$

IMU Limb $200\text{Hz} \times 6$

MEG $100\text{Hz} \times 12$



Functional groups



Kober H. et al. Functional grouping and cortical–subcortical interactions in emotion: A meta-analysis of neuroimaging studies // Neuroimage. 2008 Aug 15; 42(2): 998–1031.

Задача: Построить модель анализа активности головного мозга, учитывающую пространственную структуру сигналов.

Проблема: Из-за отсутствия регулярности структуры сигнала на сферической поверхности мозга CNN не могут быть эффективно применены для учета пространственной информации.

Решение: Предлагается рассмотреть графовое представление сигналов для учета функциональных взаимосвязей различных частей мозга в пространстве. Такое представление обосновано нерегулярной структурой физической и функциональной связи различных областей мозга. Исследуются методы построения карты связности электродов для ее последующего использования графовой моделью GCN.

Основные работы

Детерминированные методы оценки связи сигналов

Sakkalis V., Tsiaras V., Tollis I. Assessment of Linear and Nonlinear Synchronization Measures for Analyzing EEG. // Journal of Healthcare Engineering, 2010

Использованные графовые модели

Ruiz, L., Gama, F., Ribeiro, A. Gated Graph Recurrent Neural Networks. // IEEE Transactions on Signal Processing, 2020

Seo Y., Defferrard M., Vandergheynst P., Bresson X. Structured Sequence Modeling with Graph Convolutional Recurrent Networks. // Neural Information Processing, 2018

Дополнительные ссылки

Вареник Н.В. Построение карты связности функциональных групп в задаче декодирования сигналов

Duan R. N., Zhu J. Y., Lu B. L. Differential entropy feature for EEG-based emotion classification // 2013 6th International IEEE/EMBS Conference on Neural Engineering

Постановка задачи построения карты связности

$\underline{\mathbf{X}} = [\mathbf{X}_m]_{m=1}^M$, $\mathbf{X}_m \in \mathbb{R}^{E \times N}$ – исходный сигнал, N – число отсчетов времени, E – число электродов, M – число испытаний.

Дополнительно известна матрица координат электродов

$\mathbf{Z} \in \mathbb{R}^{E \times 3}$. Рассмотрим ненаправленный динамический граф:

$$\mathcal{G}(m, t) = \left(\mathcal{V}(m, t), \mathcal{E}(m, t), \mathbf{A}_{\underline{\mathbf{X}}, \mathbf{Z}}(m, t) \right),$$

в котором $\mathcal{V}(m, t)$ есть множество электродов, множество ребер $\mathcal{E}(m, t)$ и их веса определяются из матрицы связности $\mathbf{A}_{\underline{\mathbf{X}}, \mathbf{Z}}(m, t)$. Требуется найти функцию:

$$\mathbf{A}_{\underline{\mathbf{X}}, \mathbf{Z}}(m, t) : M \times T' \rightarrow \mathbb{R}_+^{E \times E}, \quad T' \subseteq T, \quad T = \{t_n\}_{n=1}^N.$$

Постановка задачи декодирования

Данные сигналов:

$\underline{\mathbf{X}} = [\mathbf{X}_m]_{m=1}^M$, $\mathbf{X}_m = [\mathbf{X}_t]_{t \in T}$, $\mathbf{X}_t \in \mathbb{R}^E$, $T = \{t_n\}_{n=1}^N$, где N – число отсчетов времени, $E = 62$ – число электродов, M – число испытаний;

Координаты электродов: $\mathbf{Z} = [\mathbf{z}_k]_{k=1}^E$, $\mathbf{z}_k \in \mathbb{R}^3$;

Целевая переменная: $\mathbf{y} = [y_m]_{m=1}^M$, C – число классов.

Априорный штраф за плотность матрицы:

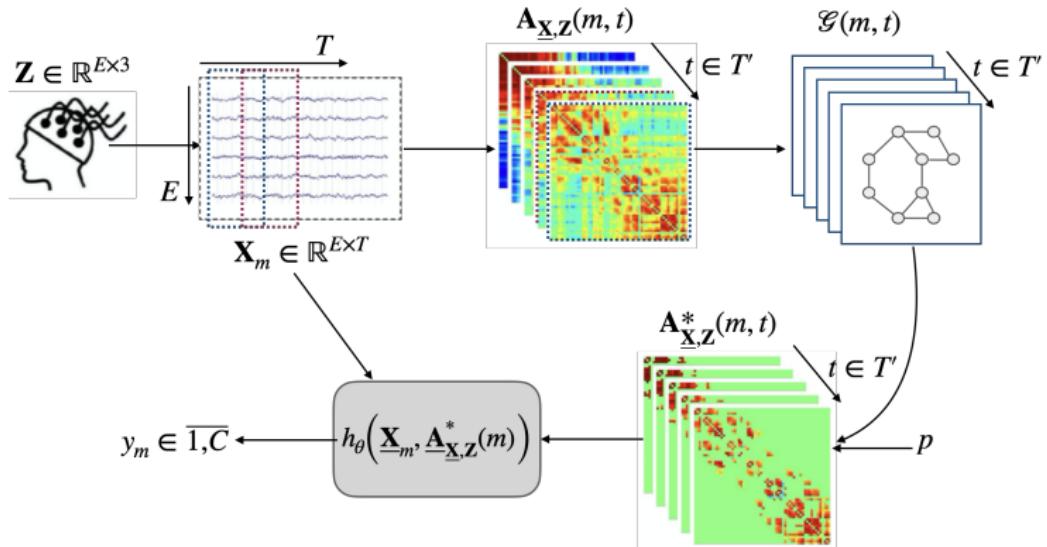
$$\mathbf{A}_{\underline{\mathbf{X}}, \mathbf{z}}^* = \arg \min_{\mathbf{A}_{\underline{\mathbf{X}}, \mathbf{z}}} \left| \|\mathbf{A}_{\underline{\mathbf{X}}, \mathbf{z}}\|_1 - p \right|, \quad p \text{ -- степень разреженности.}$$

Рассматривается класс графовых рекуррентных нейронный сетей:

$$h_\theta : (\underline{\mathbf{X}}, \mathbf{A}_{\underline{\mathbf{X}}, \mathbf{z}}^*) \rightarrow \mathbf{y}.$$

Внешний критерий качества: точность.

Графовое представление сигнала



Построение и использование графовой структуры сигнала

Способы построения карты связности

1. Евклидово расстояние между электродами
2. Корреляция Пирсона между сигналами электродов
3. Спектральная когерентность
4. Частично направленная когерентность
5. Мера синхронизации фаз

Обозначим $\mathbf{x} = \mathbf{x}_{mi}$ и $\mathbf{y} = \mathbf{x}_{mj}$ строки матрицы \mathbf{X}_m , соответствующие сигналам в отрезке времени $[t_n - T_w, t_n]$ в m -ом испытании для i и j электрода с координатами \mathbf{z}_i , \mathbf{z}_j .

Евклидово расстояние:

$$d_{ij} = \|\mathbf{z}_i - \mathbf{z}_j\|_2^2, \quad i, j \text{ — номера электродов.}$$

$$\mathbf{A}_{\underline{\mathbf{X}}, \mathbf{z}}^*(m, t) = [a_{ij}] \in \mathbb{R}_+^{E \times E}, \quad a_{ij} = \begin{cases} d_{ij}, & \text{если } d_{ij} \leq \rho(p) \\ 0, & \text{иначе.} \end{cases} \quad (0.1)$$

Линейная корреляция Пирсона:

$$\tilde{r}_{ij}(m, t_n) = \frac{\sum_{k=t_n-T_w}^{t_n} (x_k - \bar{x})(y_k - \bar{y})}{\sqrt{\sum_{k=t_n-T_w}^{t_n} (x_k - \bar{x})^2 \sum_{k=t_n-T_w}^{t_n} (y_k - \bar{y})^2}}$$

$$\mathbf{A}_{\underline{\mathbf{X}}, \underline{\mathbf{Z}}}^*(m, t) = [a_{ij}(m, t)] \in \mathbb{R}_+^{E \times E},$$

$$a_{ij}(m, t) = \begin{cases} r_{ij}(m, t), & \text{если } r_{ij}(m, t) \geq \rho(p) \\ 0, & \text{иначе,} \end{cases}$$

где $r_{ij}(m, t) = |\tilde{r}_{ij}(m, t)|.$

Спектральная когерентность

Обозначим x_{mi} и x_{mj} строки матрицы \mathbf{X}_m , соответствующие сигналам в отрезке времени $[t_n - T_w, t_n]$ в m -ом испытании для i и j электрода.

Спектральная когерентность между двумя сигналами:

$$\gamma_{ij}(m, t_n, f) = \frac{|S_{xy}(t_n, f)|^2}{S_{xx}(t_n, f)S_{yy}(t_n, f)},$$

$$\gamma_{ij}(m, t_n) = \int_{f_1}^{f_2} \gamma_{ij}(m, t_n, f) df,$$

$$\mathbf{A}_{\underline{\mathbf{X}}, \mathbf{Z}}^*(m, t) = [a_{ij}(m, t)] \in \mathbb{R}_+^{E \times E},$$

$$a_{ij}(m, t) = \begin{cases} \gamma_{ij}(m, t), & \text{если } \gamma_{ij}(m, t) \geq \rho(p) \\ 0, & \text{иначе.} \end{cases}$$

Частично направленная когерентность

Обозначим $\mathbf{x}_m(t) = [x_{m1}(t), \dots, x_{mE}(t)]^T$ набор одновременно наблюдаемых временных рядов в отрезке времени $[t_n - T_w, t_n]$ в m -ом испытании.

Рассмотрим векторную регрессионную модель порядка q :

$$\mathbf{x}_m(t) = \sum_{k=1}^q \mathbf{W}_k \mathbf{x}_m(t-k) + \mathbf{b}(t),$$

$$\mathbf{W}(f) = \sum_{k=1}^q \mathbf{W}_k e^{-i2\pi fk},$$

$$\pi_{j \rightarrow i}(m, t_n, f) = \frac{\frac{1}{\sigma_i} |\overline{\mathbf{W}}_{ij}(f)|}{\sqrt{\sum_{k=1}^q \frac{1}{\sigma_k^2} \overline{\mathbf{W}}_{kj}(f) \overline{\mathbf{W}}_{kj}^H(f)}},$$

$$\pi_{ij}(m, t_n) = \frac{1}{2} \left(\int_{f_1}^{f_2} \pi_{i \rightarrow j}(m, t_n, f) + \int_{f_1}^{f_2} \pi_{j \rightarrow i}(m, t_n, f) \right)$$

Мера синхронизации фаз

Предполагается, что две динамические системы могут иметь синхронизацию фаз, даже если их амплитуды независимы.

Обозначим $x(t)$, $y(t)$ динамические системы, соответствующие наблюдениям сигнала, x_{mi} и x_{mj} в отрезке времени $[t_n - T_w, t_n]$ в m -ом испытании. Синхронизация фаз понимается как:

$$|\phi_x(t) - \phi_y(t)| = \text{const.}$$

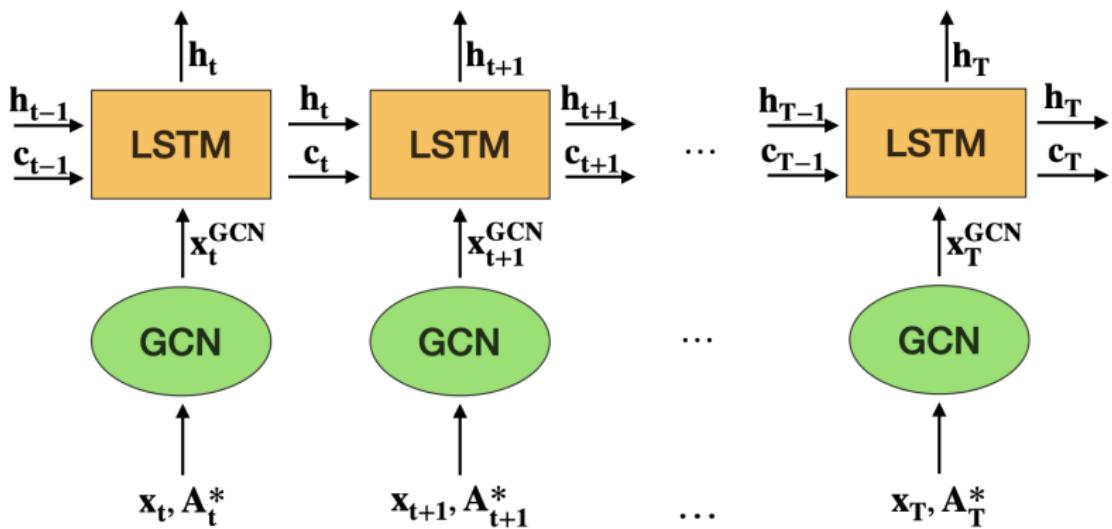
Фазы вычисляются с помощью аналитического представления сигнала с использованием преобразования Гильберта.

Значение синхронизации фаз (phase locking value):

$$p_{ij}(m, t_n) = \left| \frac{1}{T_w} \sum_{k=1}^{T_w} \exp \left(i(\phi_x(k\Delta t) - \phi_y(k\Delta t)) \right) \right|, \text{ где}$$

Δt — шаг по времени

Модель GCN LSTM



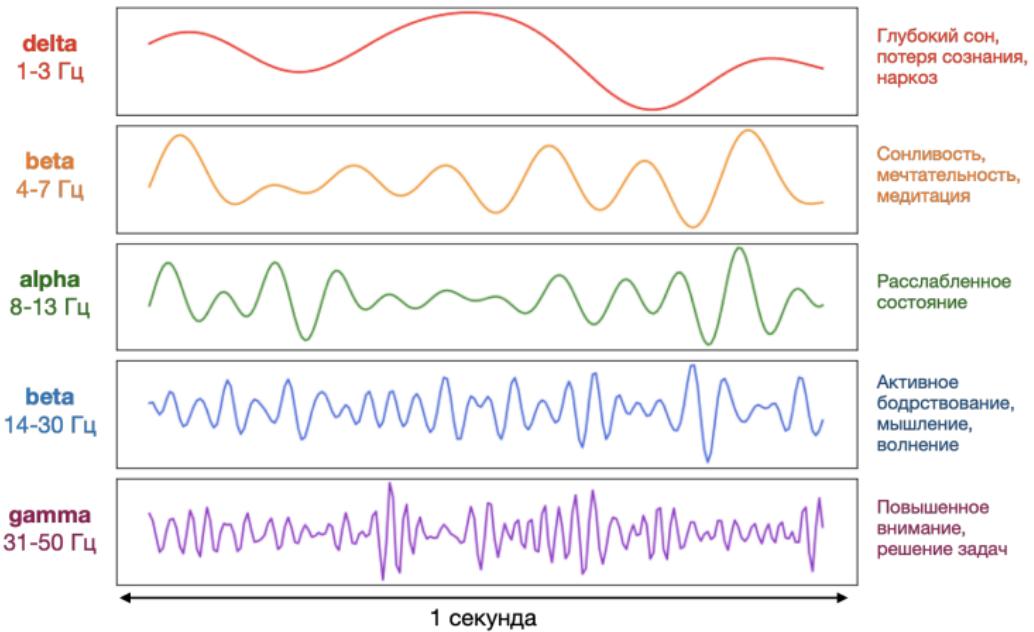
Гипотеза: Учет пространственной и функциональной структуры сигнала улучшает качество модели декодирования.

Цели:

1. Построить матрицы связей электродов рассматриваемыми методами,
2. Оценить качество работы пространственно – временной модели на основе полученных матриц.

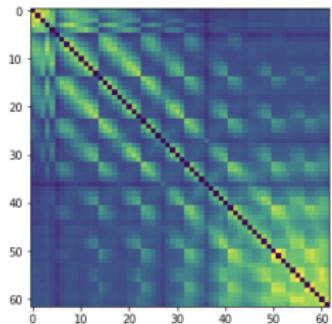
Данные: Выборка SEED по распознаванию эмоций. В качестве стимулов использовались отрывки видео, вызывающие определенные эмоциональные отклики (позитивный, негативный или нейтральный). ЭЭГ сигнал измерялся 62 электродами, частота дискретизации 200 Hz. Признаки: дифференциальная энтропия в 5 частотных диапазонах delta (1 – 3Гц), theta (4 – 7Гц), alpha (8 – 13Гц), beta (14 – 30Гц), gamma (31 – 50Гц).

Частотные полосы мозговой активности

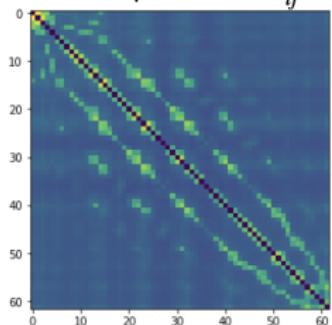


Результаты оценки матрицы сигналов

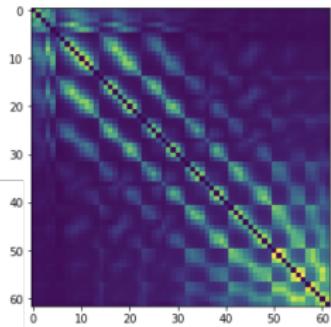
Корреляция Пирсона r_{ij}



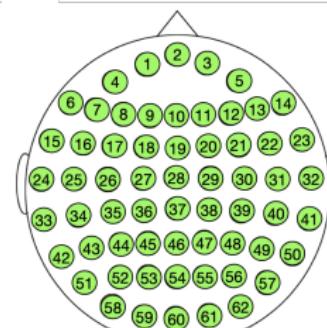
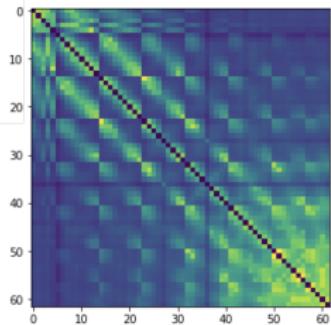
Частично направленная
когерентность π_{ij}



Когерентность γ_{ij}



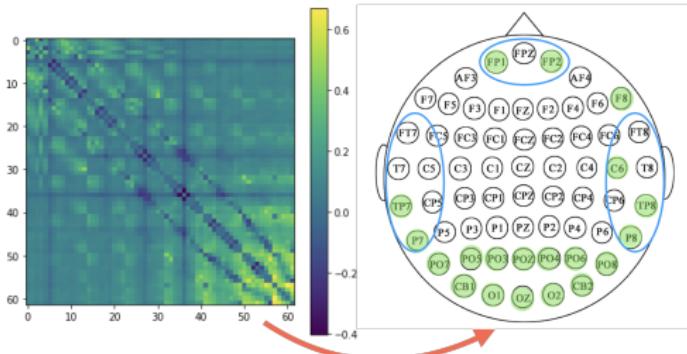
Синхронизация фаз p_{ij}



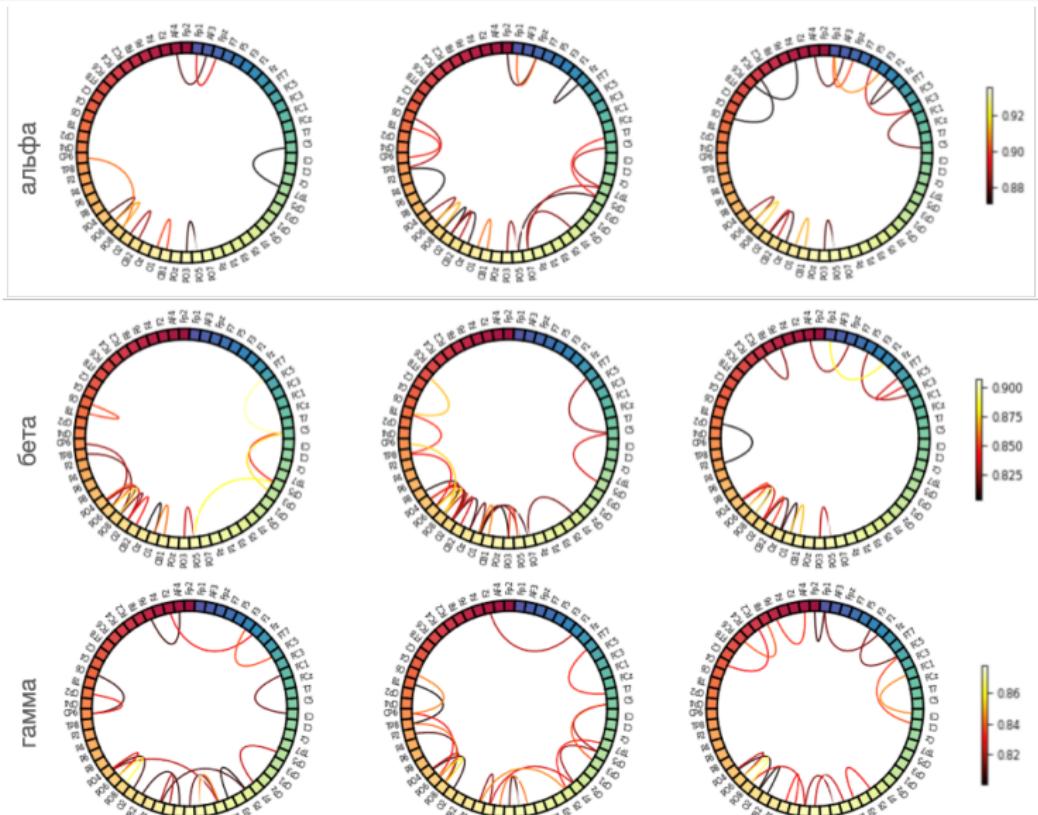
Результаты декодирования

Таблица: Сравнение LSTM и GCN LSTM

Модель	Точность	Потери
LSTM	0.869 ± 0.010	0.268 ± 0.014
GCN LSTM: d_{ij}	0.894 ± 0.013	0.220 ± 0.012
GCN LSTM: r_{ij}	0.914 ± 0.011	0.183 ± 0.009
GCN LSTM: γ_{ij}	0.898 ± 0.010	0.214 ± 0.013
GCN LSTM: π_{ij}	0.898 ± 0.007	0.213 ± 0.012
GCN LSTM: p_{ij}	0.925 ± 0.008	0.173 ± 0.014



Нейробиологическая интерпретация



1. Исследовано графовое представление сигнала, построена динамическая графовая структура.
2. Проведено сравнение различных методов оценки карты связности.
3. Предложена графово-рекуррентная модель для решения задачи декодирования.
4. Показана целесообразность использования информации о пространственной и функциональной структуре сигнала.
5. Проведена нейробиологическая интерпретация.